

语义回响 (Semantic Echo) 替代模型批次实验报告

批次: Qwen2.5-1.5B-Instruct (4bit) / Qwen2.5-7B-Instruct (4bit) 重跑 E1-E13 生成时间:
2026-08-03 数据目录: data_1_5B_4bit/、data_7B_4bit/ 对比基线: 0.5B (fp16) 批次 (实验
数据 /)

一、实验概览

本批次为「星拟图工程」验证体系的一部分: 在替代模型上重跑语义回响 E1-E13 全量实验矩阵, 验证回响机制 (λ 注入 + 指数衰减 + 情感筛选 + 思考阶段 + 保留策略) 在大模型上的可迁移性。

| 项目 | 说明 | |-----|-----| | 模型 A | Qwen2.5-1.5B-Instruct (4bit 量化), 13 个配置全跑 | | 模型 B | Qwen2.5-7B-Instruct (4bit 量化), 3 个代表配置 (E1/E3/E4) | | 提示词集 | 5 维度 $\times$ 3 条 = 15 条 (开心/悲伤/愤怒/中性/复杂混合) | | 重复次数 | 1.5B: 15 条 $\times$ 3 次重复; 7B: 15 条 $\times$ 1 次重复 | | 生成长度 | 常规实验 128 tokens; 特测 2048 tokens | | 采样参数 | temperature=1.0 / 1.0, top_p=0.9, top_k=50 | | 投影矩阵 | seed=42 静态随机投影, 仅最后一层 hook |

二、实验配置矩阵

编号	配置	λ	γ	情感筛选	思考阶段	保留策略
E1	Baseline (top_p=0.9)	—	—	X	X	—
E2	Baseline (temperature=1.0)	—	—	X	—	—
E3	Echo ($\lambda=0.5, \gamma=0.05$)	0.5	0.05	X	X	衰减
E4	Echo ($\lambda=1.0, \gamma=0.1$)	1.0	0.1	X	X	衰减
E5	Echo ($\lambda=2.0, \gamma=0.5$)	2.0	0.5	X	X	衰减
E6	Echo ($\lambda=1.0, \gamma=0.01$)	1.0	0.01	X	X	衰减
E7	Echo ($\lambda=0.5$) + 筛选	0.5	0.05	✓	X	衰减
E8	Echo ($\lambda=1.0$) + 筛选	1.0	0.1	✓	X	衰减
E9	Echo ($\lambda=0.5$) + 筛选 + 思考	0.5	0.05	✓	✓	衰减
E10	Echo ($\lambda=1.0$) + 筛选 + 思考	1.0	0.1	✓	✓	衰减
E11	Echo ($\lambda=0.5$) + 筛选 + 滑动窗口3轮	0.5	0.05	✓	X	滑动窗口
E12	Echo ($\lambda=1.0$) + 筛选 + 滑动窗口3轮	1.0	0.1	✓	X	滑动窗口
E13	Echo ($\lambda=0.5$) + 筛选 + 全局保留	0.5	0.05	✓	X	全局保留

三、测试环境

| 项目 | 值 | |-----|-----| | 操作系统 | Windows | | 模型 A / B | Qwen2.5-1.5B-Instruct / Qwen2.5-7B-Instruct (4bit, bitsandbytes 量化) | | 对比基线模型 | Qwen2.5-0.5B-Instruct (fp16) | | 框架 | transformers + torch, 语义回响 semantic_echo 包 (seed=42 投影) | | 生成参数 | max_new_tokens=128 (特测 2048), do_sample=True | | 采样 | temperature=1.0, top_p=0.9, top_k=50 |

7B 的隐藏层向量能量更强，注入扰动更大。

六、长文本压力测试（特测_2048）

| 模型 | 平均熵 | 重复率 | 步数 | 生成用时(s) | 池最终大小 | 熵曲线起点→稳态 | |-----|-----|-----|-----|-----|-----|-----|-----|
| 1.5B (4bit) | 0.0909 | 0.9927 | 2048 | 98.1 | 0 | 1.77 → ~0.05 | | 7B (4bit) | 0.0187 | 0.9951 | 2048 | 111.8 | 0 | 1.22 → ~0.01 |

- 熵曲线采样（32 点）显示：首个 token 熵正常（1.77 / 1.22），随后**迅速坍缩至近零并持续**——典型的长文本复读循环。
- 本测试池统计为空（最终大小=0、质心范数=0），即**未发生回响注入**，说明 2048 token 长生成下 4bit 模型本身即退化为复读机。
- 7B 熵曲线非零占比仅 37.5%，退化比 1.5B（93.8%）更彻底。

七、与 0.5B (fp16) 旧批次对比

| 实验 | 0.5B 熵 | 1.5B(4bit) 熵 | 变化 | 结论 | |-----|-----|-----|-----|-----| | E1 基线 | 1.8011 | 1.6378 | -9.1% | 基线基本稳定 | | E2 基线 | 3.7931 | 3.8984 | +2.8% | 一致 | | E3 $\lambda=0.5$ | 2.1240 (**提升** +17.9%) | 0.1295 | 机制失效 | 0.5B 上回响提升多样性，1.5B 上直接坍缩 | | E4 $\lambda=1.0$ | 0.7199 | 0.0661 | 坍缩加剧 | 两个模型都坍缩，1.5B 更严重 | | E7 $\lambda=0.5$ +筛选 | 2.1352 | 0.4814 | 缓解但不足 | 筛选在 0.5B 保持高熵，在 1.5B 仅勉强救回一半 | | E13 全局保留 | 1.9372 | 0.5295 | 同向降级 | 保留策略同样不可迁移 |

核心结论：语义回响机制在 0.5B 上验证有效的“提升多样性”效应，无法迁移到 1.5B/7B 4bit 模型，且由“提升”翻转为“灾难性坍缩”。

八、问题与风险

| 编号 | 问题描述 | 严重程度 | 状态 | 分析 | |-----|-----|-----|-----|-----| | 1 | 回响注入导致 logits 坍缩，重复率 83%~98% | **高** | 待修复 | 0.5B 的 hidden_state 能量与 logits 量级匹配良好；1.5B/7B 隐藏层范数更大（质心范数 250~450），同 λ 注入使 logits 峰值锁定到单 token，softmax 后熵趋零 | | 2 | 情感筛选仅部分缓解（熵 0.38~0.53），不足以恢复可用性 | 中 | 待修复 | 筛选缩小了回响池规模，但注入强度本身仍过高 | | 3 | 7B 批次仅 1 次重复，统计噪声大 | 低 | 待补充 | 7B 每 prompt 只生成 1 次，无法计算方差 | | 4 | 4bit 量化与模型规模构成混淆变量 | 中 | 待验证 | 0.5B 为 fp16，1.5B/7B 为 4bit；无法区分是“规模增大”还是“量化误差”导致 | | 5 | 特测_2048 池统计全零但重复率 99% | 中 | 已确认 | 无回响注入时 4bit 模型长文本仍复读，属模型本身长上下文退化，与回响无关 | | 6 | E9 思考阶段反而劣于 E7（0.381 vs 0.481） | 低 | 已确认 | 思考阶段在坍缩场景下无收益 |

九、结论与建议

结论：新批次验证失败——语义回响机制不可直接迁移至 1.5B/7B 4bit 模型，所有回响配置均出现严重重复坍塌（重复率 83%~98%），且长文本（2048 token）下 4bit 模型自身也退化为复读机。

建议：

1. **按模型规模缩放注入强度：** λ 需随 hidden_dim 增大而降低（如 $\lambda' = \lambda \times (\text{hidden_dim}_{0.5B} / \text{hidden_dim})$ ），或改为对注入向量做归一化后再乘 λ 。
2. **隔离量化变量：**用 fp16 的 1.5B 重跑 E3/E4/E13，确认坍塌主因是规模还是 4bit 量化。
3. **加入重复惩罚：**生成时启用 repetition_penalty，作为坍塌兜底。
4. **补充 7B 实验：**将重复次数补到 3 次，补齐 E7/E9/E13 等代表配置。
5. **特测结论：**2048 token 长生成需配合 sliding window KV cache 与重复抑制，否则 4bit 模型不可用于长文输出。
6. **临时脚本清理：**聚合脚本 `_聚合统计.py` 已从本目录移除。

附录：数据文件清单

- `data_1_5B_4bit/`：E1~E13.json（13 个配置 × 15 提示词 × 3 重复）+ 特测_2048.json
- `data_7B_4bit/`：E1.json、E3.json、E4.json（各 15 提示词 × 1 重复）+ 特测_2048.json
- 对比基线：`实验数据/E1~E13.json`（0.5B fp16 旧批次）