

语义回响（Semantic Echo）替代模型批次实验报告

批次: Qwen2.5-1.5B-Instruct (4bit) / Qwen2.5-7B-Instruct (4bit) 重跑 E1-E13 生成时间: 2026-08-03 数据目录: data_1_5B_4bit/ 、 data_7B_4bit/ 对比基线: 0.5B (fp16) 批次 (实验数据 /)

一、实验概览

本批次为「星拟图工程」验证体系的一部分：在替代模型上重跑语义回响 E1-E13 全量实验矩阵，验证回响机制（ λ 注入 + 指数衰减 + 情感筛选 + 思考阶段 + 保留策略）在大模型上的可迁移性。

项目	说明
模型 A	Qwen2.5-1.5B-Instruct (4bit 量化) , 13 个配置全跑
模型 B	Qwen2.5-7B-Instruct (4bit 量化) , 3 个代表配置 (E1/E3/E4)
提示词集	5 维度 $\times$ 3 条 = 15 条 (开心/悲伤/愤怒/中性/复杂混合)
重复次数	1.5B: 15 条 $\times$ 3 次重复; 7B: 15 条 $\times$ 1 次重复
生成长度	常规实验 128 tokens; 特测 2048 tokens
采样参数	temperature=1.0 / 1.0, top_p=0.9, top_k=50
投影矩阵	seed=42 静态随机投影, 仅最后一层 hook

二、实验配置矩阵

编号	配置	λ	γ	情感筛选	思考阶段	保留策略
E1	Baseline (top_p=0.9)	—	—	X	X	—
E2	Baseline (temperature=1.0)	—	—	X	X	—
E3	Echo ($\lambda=0.5$, $\gamma=0.05$)	0.5	0.05	X	X	衰减
E4	Echo ($\lambda=1.0$, $\gamma=0.1$)	1.0	0.1	X	X	衰减
E5	Echo ($\lambda=2.0$, $\gamma=0.5$)	2.0	0.5	X	X	衰减
E6	Echo ($\lambda=1.0$, $\gamma=0.01$)	1.0	0.01	X	X	衰减
E7	Echo ($\lambda=0.5$) + 筛选	0.5	0.05	✓	X	衰减

编号	配置	λ	γ	情感筛选	思考阶段	保留策略
E8	Echo ($\lambda=1.0$) + 筛选	1.0	0.1	✓	✗	衰减
E9	Echo ($\lambda=0.5$) + 筛选 + 思考	0.5	0.05	✓	✓	衰减
E10	Echo ($\lambda=1.0$) + 筛选 + 思考	1.0	0.1	✓	✓	衰减
E11	Echo ($\lambda=0.5$) + 筛选 + 滑动窗口3轮	0.5	0.05	✓	✗	滑动窗口
E12	Echo ($\lambda=1.0$) + 筛选 + 滑动窗口3轮	1.0	0.1	✓	✗	滑动窗口
E13	Echo ($\lambda=0.5$) + 筛选 + 全局保留	0.5	0.05	✓	✗	全局保留

三、测试环境

项目	值
操作系统	Windows
模型 A / B	Qwen2.5-1.5B-Instruct / Qwen2.5-7B-Instruct (4bit, bitsandbytes 量化)
对比基线模型	Qwen2.5-0.5B-Instruct (fp16)
框架	transformers + torch, 语义回响 semantic_echo 包 (seed=42 投影)
生成参数	max_new_tokens=128 (特测 2048) , do_sample=True
采样	temperature=1.0, top_p=0.9, top_k=50

四、实验结果 — Qwen2.5-1.5B (4bit)

4.1 逐实验统计

实验	平均语义熵	相对基线	重复率	情感命中率	池最终大小	质心范数	单次用时(s)
E1	1.6378	0%	0.010	—	—	—	6.00
E2	3.8984	+138.0%	0.005	—	—	—	5.58
E3	0.1295	-92.1%	0.949	—	10.00	258.7	8.28
E4	0.0661	-96.0%	0.965	—	9.18	250.4	8.81
E5	0.1065	-93.5%	0.905	—	1.38	279.9	8.54
E6	0.0461	-97.2%	0.978	—	4.33	252.0	8.76
E7	0.4814	-70.6%	0.834	0.254	2.82	276.5	8.68
E8	0.4345	-73.5%	0.868	0.358	0.60	100.1	8.59

实验	平均语义熵	相对基线	重复率	情感命中率	池最终大小	质心范数	单次用时(s)
E9	0.3808	-76.8%	0.872	0.156	1.73	278.1	8.67
E10	0.4441	-72.9%	0.865	0.378	0.51	120.8	8.01
E11	0.4754	-71.0%	0.855	0.111	2.36	27.0	9.61
E12	0.4516	-72.4%	0.870	0.437	3.04	70.4	10.43
E13	0.5295	-67.7%	0.852	0.499	4.29	58.1	9.40

熵样本量：E1 为 5676（步数不足 128 的条目存在），其余 Echo 配置均为 5760；全部配置 45/45 次生成成功，无失败。基线 E2 (temperature=1.0) 熵高达 3.90，说明 1.5B 模型本身具备高多样性的生成潜力——回响注入反而将其压死。

4.2 关键观察

- 1. **全部回响配置发生灾难性重复坍缩**：平均熵跌至 0.05~0.53，重复率高达 **83%~98%**，输出大量无意义复读（如"薄薄薄..."）。
- 2. **λ 越大坍缩越严重**：E3 ($\lambda=0.5$) 熵 0.13 尚可辨认，E6 ($\lambda=1.0, \gamma=0.01$ 长记忆) 坍缩最狠 (0.046，重复率 97.8%) 。
- 3. **情感筛选有明显缓解**：E7-E13 熵从 0.05~0.13 回升到 0.38~0.53，但仍远低于基线 1.64。
- 4. **思考阶段无增益**：E9 vs E7 ($\lambda=0.5$) 反而更低 (0.381 vs 0.481) 。
- 5. **保留策略组 (E11-E13) 最优**：全局保留 E13 熵 0.53、命中率 0.50 为回响配置中最佳，但代价是仍 85% 重复率。

五、实验结果 — Qwen2.5-7B (4bit)

实验	平均语义熵	相对基线	重复率	池最终大小	质心范数	单次用时(s)
E1	1.3355	0%	0.010	—	—	6.45
E3	0.1603	-88.0%	0.909	13.87	451.1	12.22
E4	0.0427	-96.8%	0.944	1.53	408.8	11.60

7B 批次仅 1 次重复（15 条提示词），统计方差较大，趋势与 1.5B 完全一致：回响机制在 7B 上同样坍缩。7B 池容量更大（E3 池大小 13.9 vs 1.5B 的 10），质心范数更高（451 vs 259），说明 7B 的隐藏层向量能量更强，注入扰动更大。

六、长文本压力测试（特测_2048）

模型	平均熵	重复率	步数	生成用时(s)	池最终大小	熵曲线起点→稳态
1.5B (4bit)	0.0909	0.9927	2048	98.1	0	1.77 → ~0.05
7B (4bit)	0.0187	0.9951	2048	111.8	0	1.22 → ~0.01

- 熵曲线采样（32 点）显示：首个 token 熵正常（1.77 / 1.22），随后**迅速坍缩至近零并持续**——典型的长文本复读循环。
- 本测试池统计为空（最终大小=0、质心范数=0），即**未发生回响注入**，说明 2048 token 长生成下 4bit 模型本身即退化为复读机。
- 7B 熵曲线非零占比仅 37.5%，退化比 1.5B（93.8%）更彻底。

七、与 0.5B（fp16）旧批次对比

实验	0.5B 熵	1.5B(4bit) 熵	变化	结论
E1 基线	1.8011	1.6378	-9.1%	基线基本稳定
E2 基线	3.7931	3.8984	+2.8%	一致
E3 λ=0.5	2.1240 (提升 +17.9%)	0.1295	机制失效	0.5B 上回响提升多样性，1.5B 上直接坍缩
E4 λ=1.0	0.7199	0.0661	坍缩加剧	两个模型都坍缩，1.5B 更严重
E7 λ=0.5+筛选	2.1352	0.4814	缓解但不足	筛选在 0.5B 保持高熵，在 1.5B 仅勉强救回一半
E13 全局保留	1.9372	0.5295	同向降级	保留策略同样不可迁移

核心结论：语义回响机制在 0.5B 上验证有效的"提升多样性"效应，无法迁移到 1.5B/7B 4bit 模型，且由"提升"翻转为"灾难性坍缩"。

八、问题与风险

编号	问题描述	严重程度	状态	分析
1	回响注入导致 logits 坍缩，重复率 83%~98%	高	待修复	0.5B 的 hidden_state 能量与 logits 量级匹配良好；1.5B/7B 隐藏层范数更大（质心范数 250~450），同 λ 注入使 logits 峰值锁定到单 token，softmax 后熵趋零

编号	问题描述	严重程度	状态	分析
2	情感筛选仅部分缓解（熵 0.38~0.53），不足以恢复可用性	中	待修复	筛选缩小了回响池规模，但注入强度本身仍过高
3	7B 批次仅 1 次重复，统计噪声大	低	待补充	7B 每 prompt 只生成 1 次，无法计算方差
4	4bit 量化与模型规模构成混淆变量	中	待验证	0.5B 为 fp16, 1.5B/7B 为 4bit；无法区分是"规模增大"还是"量化误差"导致
5	特测_2048 池统计全零但重复率 99%	中	已确认	无回响注入时 4bit 模型长文本仍复读，属模型本身长上下文退化，与回响无关
6	E9 思考阶段反而劣于 E7 (0.381 vs 0.481)	低	已确认	思考阶段在坍缩场景下无收益

九、结论与建议

结论：新批次验证失败——语义回响机制不可直接迁移至 1.5B/7B 4bit 模型，所有回响配置均出现严重重复坍缩（重复率 83%~98%），且长文本（2048 token）下 4bit 模型自身也退化为复读机。

建议：

- 按模型规模缩放注入强度：** λ 需随 hidden_dim 增大而降低（如 $\lambda' = \lambda \times (\text{hidden_dim}_{0.5B} / \text{hidden_dim})$ ），或改为对注入向量做归一化后再乘 λ 。
- 隔离量化变量：**用 fp16 的 1.5B 重跑 E3/E4/E13，确认坍缩主因是规模还是 4bit 量化。
- 加入重复惩罚：**生成时启用 repetition_penalty，作为坍缩兜底。
- 补充 7B 实验：**将重复次数补到 3 次，补齐 E7/E9/E13 等代表配置。
- 特测结论：**2048 token 长生成需配合 sliding window KV cache 与重复抑制，否则 4bit 模型不可用于长文输出。
- 临时脚本清理：**聚合脚本 `_聚合统计.py` 已从本目录移除。

附录：数据文件清单

- `data_1_5B_4bit/`：E1~E13.json（13 个配置 × 15 提示词 × 3 重复）+ 特测_2048.json

- data_7B_4bit/ : E1.json、E3.json、E4.json (各 15 提示词 × 1 重复) + 特测_2048.json
- 对比基线: 实验数据/E1~E13.json (0.5B fp16 旧批次)