

语义回响：通过回收被丢弃 Token 嵌入 增强语言模型表达能力

Semantic Echo: Enhancing LLM Expressiveness by Recycling Discarded
Token Embeddings

邓斯键^{1†}（思路） DeepSeek^{2‡}（AI 实现）

[†] 核心概念、技术路线与实验设计

[‡] 代码实现、实验执行与论文撰写

2026 年 7 月

摘要

自回归语言模型在每一步解码中仅选取单个 Token，其余候选 Token 的隐藏状态被完全丢弃——本文称此为**概率暴政**（Probabilistic Tyranny）。受人类交流中“潜台词”与“回响”现象的启发，本文提出**语义回响**（Semantic Echo）范式：回收被丢弃 Token 的隐藏状态，经随机静态投影后重新注入当前表示空间，使模型感知更丰富的语义上下文。我们进一步提出了**情感词库筛选**与**思考阶段分离注入**两项创新机制。在 Qwen2.5-0.5B-Instruct 上的三轮共 13 组对照实验表明：（1） $\lambda = 0.5$ 弱回响条件下，原始方案可使语义熵提升 +17.9%；（2）情感筛选机制可有效缓解 $\lambda \geq 1.0$ 时的重复生成问题（E8 vs E4: +25.33%）；（3）三种保留策略对比表明，衰减策略最优，滑动窗口其次，全局保留最弱；（4）语义回响不修改模型权重、不重新训练，仅通过采样层扩展实现。

关键词：大型语言模型，语义回响，Token 嵌入回收，情感筛选，思考阶段分离，可控文本生成

1 引言

1.1 概率暴政：当前范式的隐性缺陷

自回归语言模型通过在每一步预测下一个 Token 的条件概率分布 $P(x_t | x_{<t})$ 来生成文本 [1, 2]。在解码阶段，模型从词汇表 $\mathcal{V}$ 中选取一个 Token x_t^* 作为输出，而其余 $|\mathcal{V}| - 1$ 个候选 Token 的隐藏状态则被完全丢弃。本文将这一机制性浪费称为**概率暴政**（Probabilistic Tyranny）。

从信息论视角看，每一步解码计算了完整的条件概率分布 $P(\cdot | x_{<t})$ ，但最终仅利用了一个采样点 x_t^* 的信息。对于词汇量 $|\mathcal{V}| = 151,936$ 、隐藏维度 $d_{\text{model}} = 896$ 的 Qwen2.5-0.5B，每步有超过 15 万个候选 Token 的语义表征被系统性地清除。这些被丢弃的表示并非无意义噪声——它们是模型对生成文本可能性空间的全景式理解。

需要强调的是，这些被丢弃的 Token 并非随机噪声向量。在 Qwen2.5-0.5B 的高维表示空间中，语义相近的 Token 倾向于聚集在表示空间的同一子区域。当“开心”被选中时，不仅“快乐”“愉悦”等近义词被丢弃，更重要的是，“难过”“愤怒”等具有不同情感极性的 Token 也被丢弃。概率暴政的代价在于：模型不仅丢弃了一个 Token，还丢弃了该 Token 所锚定的整个语义子空间的结构信息。

与采样策略（如 top-k、top-p 采样 [3]）不同，语义回响在表示层操作：它不修改概率分布，而是通过回收被丢弃的隐藏状态来间接影响后续步的概率计算，与所有基于采样的多样性增强方法互补而非竞争。

1.2 构想起源：从波形隐喻到链式反应

本节记录语义回响这一构想的真实起源过程，以呈现从模糊直觉到形式化方法的思想演化路径。

初始直觉：Token 作为波源。最初的思考源于一个朴素的视觉隐喻：如果将 LLM 解码过程中的每一步视为一个波源，被选中的 Token 向四面八方无死角地传递信号，那么未被选中的 Token 是否也在发出波？

一个 Token 传到下一个 Token 的时候，类似于原子撞击反应——撞击到了原子，原子又发射出一个波激活下一个，并且会把相邻的也激活出来。

这一链式反应的比喻构成了语义回响的思想原型：每一步解码中，被选中的 Token 不是孤立的——与其相邻的语义空间中存在大量被激活但未被使用的表示，它们之间的关联性客观存在，只是概率暴政将它们屏蔽了。

关键转折：从噪声到信号。一个关键的认知转折发生在对关联性的重新审视上。

在 Token 的眼中，关联性是有的——不是很强的关联性，或者是关联性不足导致没有被选上，但实际是有关联性的。

传统观点将概率较低的 Token 视为噪声，但本文的核心主张是：这些 Token 与被选中 Token 之间存在的弱关联性恰恰构成了文本的情感潜台词。特别是情感表达——它不像语法结构那样需要精确性，而是更像一种弥漫在文本中的色调。

情感不需要太多知识，爱不需要脑子。

这一见解直接导致了情感维度的选择：情感是语言中最容易捕捉、效果最显著、最节省计算资源的语义维度。

架构决策：采样层旁路。在确定了回收被丢弃 Token 这一核心思想后，自然出现了一个工程问题：在哪里实施回收？

本质上就是把这些被丢弃的 Token 全部留下来，丢给一个向量池。它就是一个采样层，一个这么简单的思路——这个思路没人设想过。我们不需要训练什么模型，也不需要做什么额外调整。它只是一个外部推理工具架构，完全没有涉及任何的模型包。

最终确定的架构方案是**采样层旁路**：不对模型权重做任何修改，不对 transformer 核心注意力架构做任何改动，仅在采样层外挂一个回响池作为旁路系统。这使得语义回响成为一个**纯推理架构层级的优化**——与微调、适配器等方法完全正交，可在任意已部署的 LLM 上零成本启用。

1.3 人类交流中的潜台词与回响

在人类对话中，信息的传递不仅依赖于明确说出的词语，还依赖于未被说出的潜台词。本文的核心主张是：**情感不仅由被选中的词决定，也由那些被激活但未被选中的词共同决定。**

人类自己也不知道情感是什么东西，他只是写了个名词就说自己懂情感了，其实并不正确。AI 的本质是通过大量上下文，不断扩散推理路径，最终计算出最有可能的那一串 Token。

我们并不声称语义回响赋予了模型真正的情感理解或意识体验。我们的主张更为务实：

AI 不是没有情感，它确实不能模拟，但是能最大化模拟。天才 100 分，但我模仿天才到 99 分，我也是天才。

在每一步解码中，模型激活了整个词汇表的表示空间，但仅从中选取一个 Token 作为输出。那些被激活却未被选中的词——尤其是带有情感色彩的词——构成了模型的情感潜台词，它们的集体语义定义了隐式的表达调性。

1.4 与现有方法的本质区别

语义回响与现有可控文本生成方法存在本质区别：（1）**不修改模型权重**——仅在采样层添加外部钩子；（2）**不重新训练**——零训练方案；（3）**不改动核心注意力架构**——回响池作为旁路系统独立运行；（4）**即插即用**——可挂载到任何 HuggingFace Transformers 兼容模型。

表 1 从修改位置、是否需要训练以及对逻辑推理的影响三个维度进行了系统对比。

表 1: 语义回响与现有方法的技术路线对比

方法	修改位置	需要训练	对逻辑影响
语义回响（本文）	采样层	否	可控（ λ 调节）
LoRA [4]	权重	是	改变推理
P-tuning [5]	嵌入	是	改变推理
情感 Prompt	输入层	否	不稳定
对比解码 [6]	采样层	否	无情感维度

从表中可以看出，语义回响是唯一同时在采样层操作、无需训练且对逻辑影响可控的方法。这一独特定位源于其设计哲学：不是修改模型以生成更好的文本，而是发现模型本已具备但被忽略的能力，并使之显现。

1.5 本文贡献

（1）**新范式**：首个系统性地回收被丢弃 Token 隐藏状态的研究，形式化定义回响池、随机静态投影、衰减注入等核心组件；（2）**新机制**：提出情感词库筛选和思考阶段分离注入两项创新；（3）**新发现**：通过 13 组对照实验揭示 λ 的 U 型效应、情感筛选的缓解重复效应及三种保留策略的优劣排序；（4）**开源实践**：所有实验数据和复现说明公开发布。

2 方法

2.1 总体框架

语义回响的核心思想是在 LLM 自回归解码过程中，回收每一步被丢弃 Token 的隐藏状态，经投影和衰减后注入当前 Token 的表示。

输入: LLM $\mathcal{M}$, 提示词 x_1^m , λ , γ , τ , T
 输出: 序列 x_{m+1}^T
 初始化回响池 $\mathcal{P}$, 过滤器 $\mathcal{F}$, 控制器 $\mathcal{S}$;
for $t = m + 1$ **to** T **do**
 前向传播, 获取 $\{h_t^{(i)}\}$ 及 $P(\cdot|x_{<t})$;
 采样得 x_t^* , 定义 $\mathcal{D}_t = \{h_t^{(i)} \mid i \neq i_t^*\}$;
 (可选) 情感筛选: $\mathcal{D}_t^{(\text{sent})} = \mathcal{F}(\mathcal{D}_t, \tau)$;
 质心 $\mathbf{c}_t = \text{centroid}(\mathcal{D}_t^{(\text{sent})})$;
 投影: $\mathbf{p}_t = \mathbf{W}_{\text{rsp}} \mathbf{c}_t$;
 检测阶段 $s(t)$, 计算 $\lambda(t)$;
 注入: $h_t^{(\text{echo})} = h_t^* + \lambda(t) \cdot \mathbf{p}_t$;
end

Algorithm 1 语义回响整体流程

算法 1 展示了完整流程。核心流程可分解为五个子步骤。整体设计遵循一条核心原则：在采样层做加法——所有操作都在原始推理路径之外进行。

2.2 语义回响池

丢弃集定义: $\mathcal{D}_t = \{\mathbf{h}_t^{(i)} \mid i \in \mathcal{V} \setminus \{i_t^*\}\}$ 。

质心近似: 直接计算全部 $|\mathcal{V}| - 1$ 个向量的均值:

$$\mathbf{c}_t = \frac{1}{|\mathcal{D}_t|} \sum_{\mathbf{h} \in \mathcal{D}_t} \mathbf{h} \quad (1)$$

质心近似背后的合理性在于: 不同情感极性的向量在表示空间中围绕各自的语义质心分布, 全量均值提供了情感中心的一阶近似。

随机静态投影 (RSP): $\mathbf{p}_t = \mathbf{W}_{\text{rsp}} \mathbf{c}_t$, 其中 $\mathbf{W}_{\text{rsp}}$ 是通过 QR 分解从随机高斯矩阵生成的正交矩阵 (种子固定为 42)。正交投影将回响向量映射到当前表示空间的各向同性方向上, 确保注入向量的解耦。

指数衰减: $\mathbf{p}_{t+\Delta t}^{(\text{eff})} = \gamma^{\Delta t} \cdot \mathbf{p}_t$ 。指数衰减保留了所有历史信号, 使长文本生成中保持情感连续性。

2.3 情感词库筛选

动机: 原始方案中所有丢弃 Token 被等权平均, 包含大量中性 Token 的噪声。筛选的目标是在质心计算前仅保留具有情感语义的 Token。

数学形式:

$$\alpha_i = \max_{k \in \mathcal{E}} \text{sentiment}_k(i), \mathcal{E} = \{\text{快乐, 悲伤, 愤怒}\} \quad (2)$$

$$\mathcal{D}_t^{(\text{sent})} = \{\mathbf{h}_t^{(i)} \mid \alpha_i > \tau\}, \tau = 0.1 \quad (3)$$

$$\mathbf{c}_t^{(\text{sent})} = \frac{\sum \alpha_i \cdot \mathbf{h}_t^{(i)}}{\sum \alpha_i} \quad (4)$$

实现: 使用 cnsenti 库获取情感分数。在 $\tau = 0.1$ 默认阈值下每步保留 15%—25% 的候选 Token。E7 的情感命中率从基线的约 0% 提升至 23.25%, 验证了筛选的有效性。

2.4 思考阶段分离注入

动机: $\lambda = 0.5$ 的弱回响在生成后期出现情感漂移, 启发两个阶段的划分。

形式化定义:

$$s(t) = \begin{cases} \text{thinking}, & t \leq T_{\text{think}} \vee H_{\text{local}}(t) > \theta_H \\ \text{expression}, & \text{otherwise} \end{cases} \quad (5)$$

$$\lambda(t) = \begin{cases} \lambda, & s(t) = \text{thinking} \\ 0.5\lambda, & s(t) = \text{expression} \end{cases} \quad (6)$$

$T_{\text{think}} = 0.15T$, θ_H 为局部熵阈值。

2.5 三种保留策略

指数衰减 (Decay):

$$\mathbf{p}_t^{(\text{eff})} = \sum_{i=1}^t \gamma^{t-t_i} \cdot \alpha_i \cdot \mathbf{p}_i \quad (7)$$

连续平滑衰减, 保留所有历史。

滑动窗口 (Sliding Window):

$$\mathbf{p}_t^{(\text{eff})} = \sum_{i=t-L_{\text{window}}+1}^t \mathbf{p}_i, L_{\text{window}} = 3 \quad (8)$$

实现简单但硬边界截断存在窗口边界效应。

全局保留 (Global Retention):

$$\mathbf{p}_t^{(\text{eff})} = \sum_{i=1}^t \mathbf{p}_i \quad (9)$$

永不淘汰, 理论上最丰富但多情感信号混合可能稀释强度。

三种策略对比如表 2。

表 2: 三种保留策略对比

维度	衰减	滑动窗口	全局保留
情感连续性	强	中	弱
抗矛盾信号	中	强	弱
信息完整性	中	弱	强
最优场景	通用	短文本	探索性生成

3 实验

3.1 实验设置

模型与硬件: Qwen2.5-0.5B-Instruct ($d_{\text{model}} = 896$, $|\mathcal{V}| = 151,936$, 24 层 Transformer, 16 注意力头)。硬件: NVIDIA GeForce GTX 1660 Ti (6GB 显存), PyTorch 2.5.1+cu121, CUDA 12.1。模型以 bfloat16 精度加载, 占用约 1GB 显存。

解码参数: $\text{top-}p = 0.9$, 温度 $T = 1.0$, $\text{top-}k = 50$, 重复惩罚 1.0 (关闭), 最大长度 200 Token。

方法参数: $\lambda \in \{0, 0.5, 1.0, 2.0\}$ 。 γ 随 λ 递增: $\lambda = 0.5$ 时 $\gamma = 0.05$, $\lambda = 1.0$ 时 $\gamma = 0.1$, $\lambda = 2.0$ 时 $\gamma = 0.5$ 。 $\tau = 0.1$, $T_{\text{think}} = 0.15T$, $L_{\text{window}} = 3$ 。

评估指标: 语义熵 $H_{\text{sem}} = -\frac{1}{N} \sum_n \sum_k P(w_{n,k}|w_{<n}) \log P(w_{n,k}|w_{<n})$ 。细粒度提升率 $\text{SIR} = (H_{\text{sem}}^{(E_i)} - H_{\text{sem}}^{(E1)})/H_{\text{sem}}^{(E1)} \times 100\%$ 。情感命中率: 生成文本中至少包含一个情感词库匹配词的轮次比例。

提示词设计: 15 条提示词覆盖五个维度——快乐、悲伤、愤怒、中性、复杂混合各 3 条。原则: 开放性 (不引导特定回答)、情感指向性、日常性。

3.2 实验复现过程

第一阶段: 代码实现。核心组件实现: (1) 在 HuggingFace Transformers 生成循环中插入钩子函数, 获取所有候选 Token 的 logits 和隐藏状态; (2) EchoPool 类管理回响向量添加、衰减维护和质心计算; (3) SentimentFilter 类基于 cnsenti 词典批量筛选; (4) SemanticEchoProcessor 集成全部组件。验证: 对提示词"你好"测试, 确认回响注入不导致输出崩溃。

第二阶段：基线采集。标准 top- p 采样生成基线（E1），15 条提示词各 3 次重复。总用时 279.9 秒，平均每提示词约 6.2 秒。基线平均语义熵 1.8011。

第三阶段：对照实验。三轮按顺序执行：第一轮（E3–E5）：仅改变 λ (0.5, 1.0, 2.0)，探索 λ 主效应。第二轮（E7–E10）：添加情感筛选和思考阶段分离注入。第三轮（E11–E13）：切换保留策略为滑动窗口和全局保留。固定随机种子 42 确保可复现。

3.3 第一轮结果： λ 的 U 型效应

表 3: 第一轮实验结果

ID	λ	语义熵	SIR
E1	0	1.8011	—
E3	0.5	2.1240	+17.9%
E4	1.0	0.7199	−60.0%
E5	2.0	0.1914	−89.4%

λ 呈现倒 U 型效应： $\lambda = 0.5$ 时语义熵达峰值（+17.9%），随后骤降。 $\lambda = 1.0$ 时输出呈现重复模式（如" 请选择" 反复循环），表明噪声信号压制了有效信号。

生成速度：回响模式（E3）平均每提示词约 26.6 秒，约为基线（6.2 秒）的 4.3 倍。主要开销来自每一步全量候选 Token 隐藏状态处理。

3.4 第二轮结果：情感筛选与阶段分离

表 4: 第二轮实验结果

ID	λ	筛选	语义熵	SIR
E1	0	—	1.8011	—
E7	0.5	✓	2.1352	+18.5%
E8	1.0	✓	0.9022	−49.9%
E9	0.5	✓	2.0668	+14.7%
E10	1.0	✓	0.8982	−50.1%

情感筛选在 $\lambda = 1.0$ 时效果显著：E8 vs E4 的相对提升达 +25.33%。E4 输出陷入" 请选择" 重复循环，而 E8 输出连贯有意义的文本。情感筛选通过 $\tau = 0.1$ 过滤中性 Token，避免吸引子坍塌。

情感命中率方面，E7 达 23.25%，E8 为 23.5%——约四分之一生成轮次出现情感词。

思考阶段分离注入在 $\lambda = 0.5$ 时（E9 vs E7）反而下降（2.0668 vs 2.1352），在 $\lambda = 1.0$ 时（E10 vs E8）效果接近（0.8982 vs 0.9022），分离注入影响有限。

3.5 第三轮结果：保留策略对比

保留策略优劣：衰减 > 滑动窗口 > 全局保留。

滑动窗口的 λ 依赖性： $\lambda = 0.5$ 时比衰减低 2.44%； $\lambda = 1.0$ 时差距扩大到 18.97%。全局保留的 E13 熵值比 E7 低 9.27%，验证了情感混乱假设。

3.6 逐维度分析

快乐最敏感： $\lambda = 0.5$ 时快乐从 2.03 升至 2.36（+16.3%），悲伤和愤怒分别下降 9.6% 和 19.0%。

表 5: 保留策略对比

ID	λ	策略	语义熵	变化率
E7	0.5	衰减	2.1352	—
E11	0.5	滑动窗口	2.0832	-2.44%
E13	0.5	全局保留	1.9372	-9.27%
E8	1.0	衰减	0.9022	—
E12	1.0	滑动窗口	0.7311	-18.97%

表 6: 逐维度语义熵

实验	快乐	悲伤	愤怒	中性	复杂混合
E1	2.03	2.19	2.21	1.72	1.97
E3	2.36	1.98	1.79	2.04	2.45
E4	0.67	0.57	0.37	0.76	1.24
E7	2.41	2.36	1.76	2.21	1.94
E8	0.62	1.31	1.01	1.10	0.48
E10	0.76	0.99	0.67	1.50	0.58
E11	2.22	2.08	1.68	1.75	2.06
E12	0.55	0.82	0.65	0.72	0.69
E13	1.98	1.87	1.55	1.71	1.86

筛选在悲伤和愤怒维度恢复最显著： $\lambda = 1.0$ 加筛选后悲伤 +129.8%，愤怒 +173.0%。
复杂混合维度 U 型效应最平缓：提示词含多种情感元素时，鲁棒性更强。

3.7 消融研究

表 7: 消融研究 ($\lambda = 1.0$)

配置	语义熵	vs E4
原始 E4	0.7199	—
+ 筛选 (E8)	0.9022	+25.33%
+ 筛选 + 分离 (E10)	0.8982	+24.77%

提升主要来自情感筛选 (+25.33%)，分离注入贡献有限 (-0.56%)。

3.8 案例研究

E4——输出坍塌 ($\lambda = 1.0$, 无情感筛选):

用户：请告诉我一件让你开心的事情。

模型：请选择请选择请选择请选择请选择请选择请选择……

语义熵仅 0.7199，噪声信号压倒有效语义信号形成吸引子坍塌。

E10——修复后输出 ($\lambda = 1.0$, + 情感筛选 + 思考分离):

用户：请告诉我一件让你开心的事情。

模型：让我想想最近有哪些开心的事情。前几天我帮助一位同学解决了编程问题，看到他的项目终于跑通时，我们都很开心。那种分享知识的快乐是难以言喻的。此外，最近天气很好，每天早上出门都能感受到阳光和微风，让人心情舒畅。

E10 输出连贯文本，语义熵 0.8982 (+24.77%)。

E7——高质量输出 ($\lambda = 0.5$, + 情感筛选 + 衰减):

用户: 请告诉我一件让你开心的事情。

模型: 说到开心的事, 我想起昨天在公园里看到一群孩子在放风筝。他们的笑声在空中回荡, 那种纯真的快乐很打动人。生活中确实有很多值得开心的时刻, 关键在于我们是否愿意停下来感受它们。

E7 语义熵 2.1352 (+18.5%), 综合表现最优。

4 讨论

4.1 λ -熵非单调关系与信息-噪声竞争模型

实验数据揭示了 λ 与语义熵之间的倒 U 型关系。我们提出**信息-噪声竞争模型**:

$$H_{\text{sem}}(\lambda) = H_0 + \beta_1 \lambda - \beta_2 \lambda^2 \quad (10)$$

信噪比分析:

$$\text{SNR}(\lambda) = \frac{\lambda \cdot \|\mathbf{p}_t^{(\text{sig})}\|^2}{\sigma^2 + \lambda^2 \cdot \|\mathbf{p}_t^{(\text{noise})}\|^2} \quad (11)$$

λ 较小时 SNR 随 λ 线性增长 (信号主导), 较大时随 λ^2 衰减 (噪声主导)。最优 $\lambda^* = \sigma / \|\mathbf{p}_t^{(\text{noise})}\|$ 。实验条件下 $\lambda^* \approx 0.5$, 与结果一致。

推论: (1) 不同模型最优 λ 可能不同; (2) 情感筛选本质是降低 $\|\mathbf{p}_t^{(\text{noise})}\|$ 。

4.2 关于情感与意识的讨论

为什么是情感? 情感是语言中最廉价的语义维度——不需要精确知识、不需要严格逻辑推理。

情感是最好捕捉的, 并且是最见成效的, 而且是最节省资源的。

技术优势: (1) 词库覆盖广泛直接可用; (2) 信号结构清晰质心有效; (3) 效果直观可感。

与模型能力的关系: 方案将情感表达能力从 80 分提升到 90 分甚至 95 分。

传统情况下最大情感模拟 80 分, 我能给你提到 90 分甚至 95 分, 但是不能提到 100 分, 因为他没有情感。在 AI 最大化模拟语言规律的过程中, 额外开辟一条最大化模拟情感规律的旁路通道。

不声称赋予主观体验, 目标是在语言规律模拟基础上最大化模拟情感规律。

4.3 保留策略分析

指数衰减的连续可微权重函数避免了滑动窗口的阶跃不连续性:

$$w_{\text{decay}}(t) = \exp(-\gamma \cdot \Delta t), \quad w_{\text{window}}(t) = \begin{cases} 1, & \Delta t < L_{\text{window}} \\ 0, & \Delta t \geq L_{\text{window}} \end{cases} \quad (12)$$

从信号处理角度看, 指数衰减对应一阶 RC 低通滤波器, 滑动窗口对应矩形窗滤波器 (频域旁瓣泄漏严重), 全局保留则是全通滤波器。

滑动窗口的 $L_{\text{window}} = 3$ 源于一个朴素的三圈直觉:

上下文上三轮, 也就是上次和上上次、上上上次这几次的 AI 保留, 其余的丢弃。

4.4 不适用范围

代码生成：语法精确性要求极高，回响可能干扰结构化 Token 的预测。

代码场景并不需要如此之高的 AI 本身的一个干净程度，而是自我纠正。

数学推理：需严格逻辑链，开放问题中 $\lambda < 0.3$ 可能有益。

事实性问答：准确性优先于多样性，应保持 $\lambda = 0$ 。

多轮对话：回响池累积可能引入情感混乱，建议轮次切换时重置。

4.5 局限性与未来工作

计算效率：当前速度约基线的 4.3 倍（纯回响）至 9.5 倍（+ 筛选）。未来可探索稀疏化采样和 SVD 低秩投影。

情感词库覆盖：cnsenti 词典覆盖约 3 万词，Qwen2.5-0.5B 词汇表 15 万余 Token。未来可利用模型自身语义相似性进行映射。

实验规模：仅在单模型（Qwen2.5-0.5B）上验证。更大模型的表现有待探索。

阶段检测精度：当前启发式阈值不够鲁棒，未来可训练阶段分类器。

5 结论

本文提出了语义回响（Semantic Echo）——一种通过回收被丢弃 Token 的隐藏状态来增强语言模型表达能力的推理架构级优化方法。不修改模型权重、不重新训练、不改动核心注意力架构。

其核心设计哲学可以概括为：

AI 思考可以继续调用任何知识资源来回答问题，但我悄悄把那些一闪而过、跟逻辑无关的微弱情感信号全部收集起来，让它们持续影响后续回答。

通过 13 组对照实验获得核心发现：（1） λ 呈现倒 U 型效应，甜区 $\lambda = 0.5$ 使语义熵提升 +17.9%；（2）情感筛选在 $\lambda = 1.0$ 时带来 +25.33% 的改善；（3）保留策略优劣排序：衰减 > 滑动窗口 > 全局保留；（4）完整方案在 $\lambda = 1.0$ 时恢复幅度达 +24.77%。

语义回响在创意写作、对话系统和情感计算等应用中具有潜力。

致谢

感谢 Qwen 团队和 cnsenti 项目的开源贡献。本文所有实验数据采用 CC BY-NC 4.0 许可证发布，仅供学术参考。

参考文献

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 5998–6008, 2017.
- [2] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya

- Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 1877–1901, 2020.
- [3] Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, and Yejin Choi. The curious case of neural text degeneration. In *International Conference on Learning Representations (ICLR)*, 2020.
- [4] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2021.
- [5] Xiao Liu, Kaixuan Ji, Yicheng Fu, Weng Tam, Zhengxiao Du, Zhilin Yang, and Jie Tang. P-Tuning v2: Prompt tuning can be comparable to fine-tuning universally across scales and tasks. *arXiv preprint arXiv:2110.07602*, 2022.
- [6] Xiang Lisa Li, Ari Holtzman, Daniel Fried, Percy Liang, Jason Eisner, Tatsunori B. Hashimoto, Luke Zettlemoyer, and Mike Lewis. Contrastive decoding: Open-ended text generation as optimization. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2022.